INTERROGATION DE DONNÉES DE TYPE GRAPHE

BDLE (BASES DE DONNÉES LARGE ECHELLE)

CAMELIA CONSTANTIN -- PRÉNOM.NOM@LIP6.FR

GRAPHES DE DONNÉES : EXEMPLES ET PROPRIÉTÉS

Croissance exponentielle du volume des données

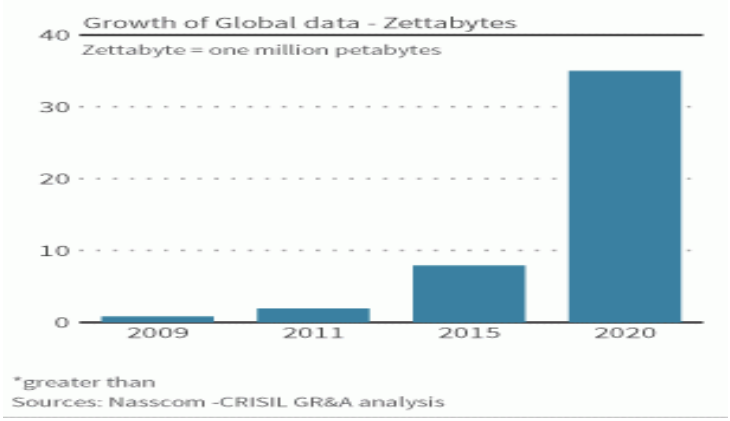

CONNECTIVITÉ DES DONNÉES

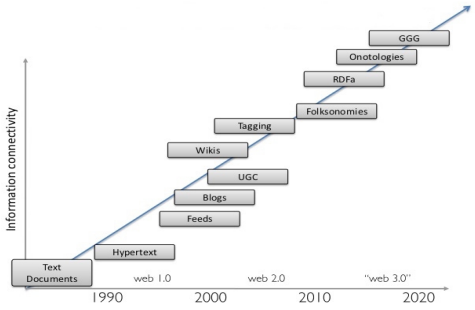

Volume x Connectivité = Complexité

RÉSEAUX SOCIAUX: des graphes gigantesques

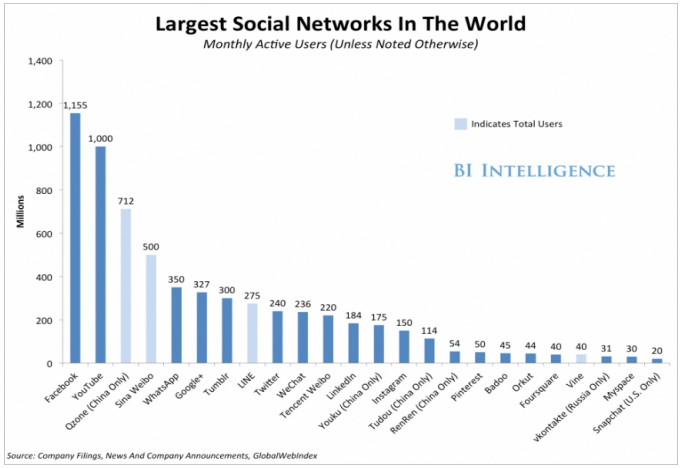

RÉSEAUX SOCIAUX (exemples 2014)

	Utilisateurs (10^6)	Arcs (10^9)
Facebook	1 300	400
LinkedIn	330	63
Twitter	650	130

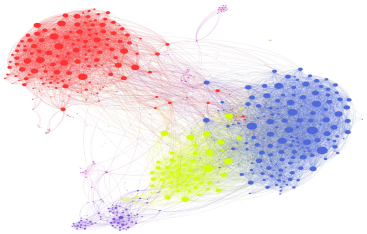

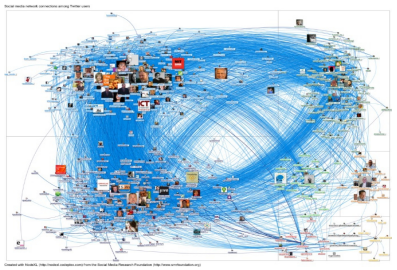

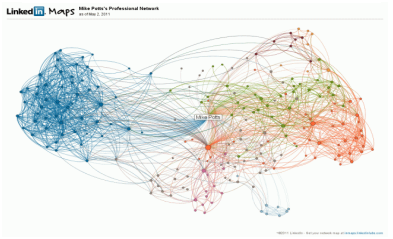

TYPES DE GRAPHE

- Graphes
  - dirigés : réseau social, citations bibliographiques web hypertexte, web sémantique, graphe de recommandation, graphe d'évolution…
  - non-dirigés : réseau routier, réseau des collaboration, graphes de cooccurrences, …

Graphes étiquetés

- nœuds : nom, age, contenu
- arcs : amitiés, coût, durée, ..

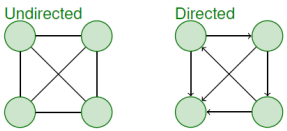

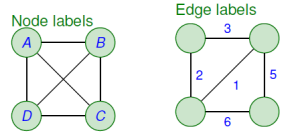

ANALYSE STATISTIQUE ET STRUCTURELLE

- Mesures de base :
  - Nombre de nœuds : |V|
  - Nombre d'arcs : |E| (plus important que |V|)
  - in/out-degree(n) : nombre d'arcs entrants/sortants
- L'histogramme d'un graphe (décrit le graphe)
  - diagramme de dispersion (d, n(d)) où n(d)=nombre de nœuds avec out-degree=d

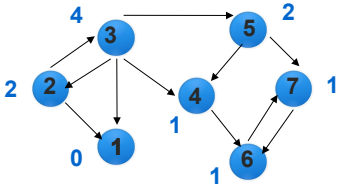

d	n(d)
0	1
1	3
2	2
3	0
4	1

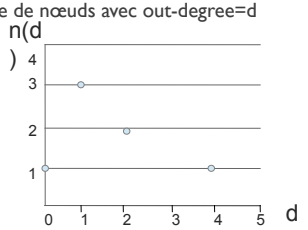

(en général cx^d pour x<1)

HISTOGRAMME : DISTRIBUTION EXPONENTIELLE

Graphe aléatoire $n(d) \simeq c(\frac{1}{2})^d$

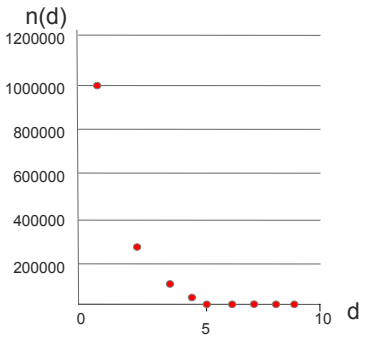

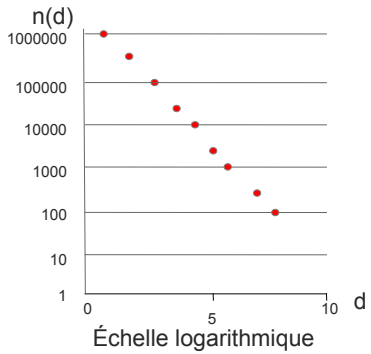

HISTOGRAMME : DISTRIBUTION ZIPF

- Graphes générés par les applications
  - graphe occurrences mots / documents
  - graphe web

$n(d) \simeq \frac{1}{d^x}, x > 0$

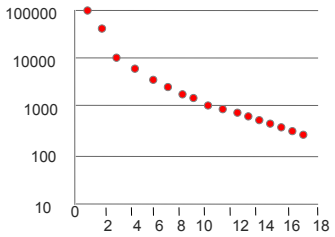

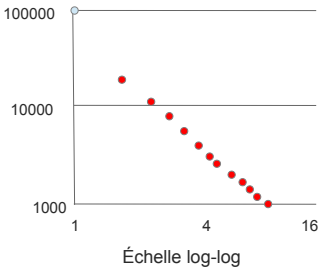

GRAPHE DU WEB

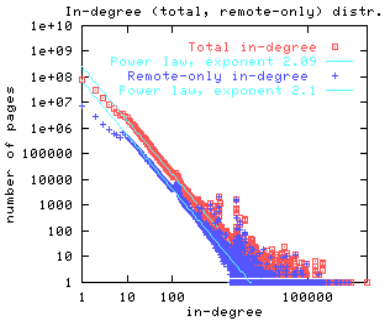

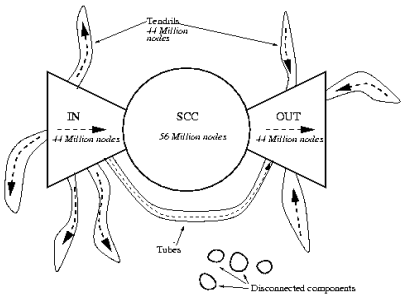

Pages Web (Broder et al.*, 2000) : A. Broder, R. Kumar, F. Maghoul, P. Raghavan, S. Rajagopalan, R. Stata, A. Tomkins, J. Wiener.Graph structure in the web. In WWW'00, pages 309-320. Crowl pages en 1999

CONNEXITÉ D'UN GRAPHE

- Degré de connexité : nombre minimum de sommets qu'on doit enlever afin de déconnecter le graphe.
- Utile pour décider si un graphe est "intéressant" pour un certain type d'analyse.

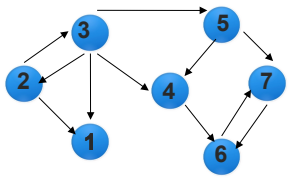

Exemple : degré de connexité du graphe ?
Degré 1 : enlever 3 on a deux composantes déconnectées

CENTRALITÉ D'UN NOEUD

- Mesure l'importance d'un sommet v
- Utile par exemple pour l'analyse de communautés
- Centralité basée sur le degré : in-degree(v)/|E|
- Centralité de proximité:
  - Distance moyenne des plus courts chemins vers ce nœud (graphe dirigé) → nœud central = a une faible distance des autre nœuds
- Centralité d'intermédiarité de v:
  - La proportion des plus courts chemins entre deux autres sommets qui passent par v

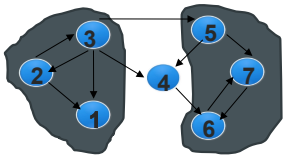

Exemple : centralité d'intermédiarité de 4 ?
(2,3,4,6), (3,4,6), (5,4,6)
3/nombre total de plus courts chemins
3/6 = 0.5

MODÉLISER ET INTERROGER LES GRAPHES DE DONNÉES

MATRICE ET LISTES D'ADJACENCE ET TABLES

compte	nom	email	…
N1	Jean	…	
N2	Lucie	…	
N3	Marc	…	

Données

follower	followee
N1	N2
N1	N3
N2	N1
N2	N3
…	…

Table d'adjacence

noeud	N1	N2	N3
N1	0	1	1
N2	0	0	0
N3	0	1	0

Matrice d'adjacence

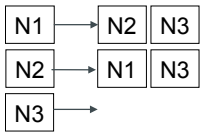

Liste d'adjacence

COMPARAISON TAILLE

Exemple :LinkedIn

- 330 millions de nœuds
- 63 milliards d'arcs
- Matrice d'adjacence
  - $330 * 10^6 * 330 * 10^6$ bits = 10^{16} bits = $1{,}2 . 10^{15}$ octets = 1,2 pétaoctets
- Table relationnelle / liste d'adjacence
  - 1 id de nœud = double = 4o
  - $63 * 10^9 * 2 * 4$ octets = $5 * 10^{11}$ octets = 0,5 téraoctets

EXEMPLES DE REQUÊTES

- Dans un réseau de type transport, alimentation, communication
  - Comment aller de l'adresse a à l'adresse b ?
  - Combien de chemins entre le nœud réseau a et le nœud réseau b ?
  - Le chemin le plus rapide entre l'usine a et le magasin b ?
- Dans un réseau de représentation de connaissance:
  - Une classe (élément) A est elle un sous-classe d'une classe B?
  - Existe-t'il un lien entre l'entité A et l'entité B?
  - Similarité entre l'entité A et l'entité B basé sur le graphe sémantique
- Réseaux de citations
  - Quels auteurs sont le plus cités directement et indirectement ?
  - Quels chercheurs / articles sont important dans un domaine (centralité) ?
- Réseaux sociaux
  - You Might Also Know de Facebook: si on partage beaucoup d'amis, on doit sans doute se connaître
  - Recommandation de lieux dans FourSquare d'après avis des amis: si des amis recommandent un lieu, alors de bonne chance que j'aime aussi
  - Degré de séparation (ex : nombre d'utilisateurs entre deux utilisateurs sur Facebook)

COMPARAISON OPÉRATIONS

Mémoire Disque

Mises-à-jour

- Matrice d'adjacence :
  - noeuds: insertion / suppression de lignes et colonnes (~ |N|)
  - arcs : maj cellule (constant)
- Liste d'adjacence
  - noeuds : creation de liste (const)
  - arcs: maj liste (~ out-degree)
- Table relationnelle
  - arcs : insertion et suppression de nuplets (depend des index)

Accès

- Matrice d'adjacence
  - operations logiques (AND, OR)
  - operations matricielle : +, -, *, T
  - matrice = index "bitmap"
- Liste d'adjacence
  - parcours de listes
- Table relationnelle
  - langages de requêtes
  - stockage et indexation

RECHERCHE DE MOTIFS

- Trouver toutes les instances d'un motif (peut contenir des étiquettes de sommets ou d'arrêtes)
- Exemple de motif :

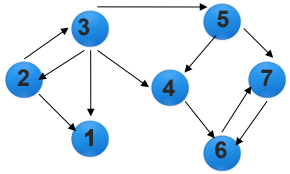

Instanciation :

- $x = 2, $y=3 ($x=3, $y=2)
- $x = 7, $y=6 ($x=6, $y=7)

EXEMPLE DE RECHERCHE DE MOTIFS : TRIANGLES

- Trouver les triangles ayant le motif : $x → $y → $z → $x (nombre total de triangles= autre mesure de connexité)
- Il existe beaucoup d'algorithmes. Un algorithme naïf trouvera le même triangle plusieurs fois :

  $x → $y → $z → $x

  $y → $z → $x → $y

  $z → $x → $y → $z

EXEMPLES DE REQUÊTES (SUITE)

- Les voisins de A
- Voisins en commun entre A et B
- Existence / nombre de chemins entre A et B (et nombre, longueur, coût, etc.)
- Existence de chemins entre A et B correspondant à une expression régulière (A B)*(C|D)+
- Recherche du plus court chemin entre A et B, entre tous les nœuds
- Recherche de motifs de graphes : cycles, "motifs de graphes", arbre couvrant, circuit hamiltonien
- Calcul de propriétés : diamètre du graphe, centralité, ..

LANGAGES DE REQUÊTES GRAPHES

LANGAGES DE REQUÊTES GRAPHE

- SQL2 : PL/SQL avec boucles et condition d'arrêt suivant la requête (pas de suivant, profondeur voulue, etc.)
- Requêtes hiérarchiques (clause CONNECT BY), Oracle7
- SQL3 : Requêtes récursives (clause WITH), Oracle 11gR2
- DATALOG : modèle théorique base sur les clauses de Horn, des implantations mais pas de produits véritables
- SPARQL : équivalent à SQL pour des données RDF (triplets : sujet, prédicat, objet = arrête étiquetée dans un graphe)
- Cypher : pour la BD graphe Neo4j
- …....

SQL : EXEMPLE DE REQUÊTE

- Trouver les voisins directs :
  - Le nom des utilisateurs qui suivent 'Marc'?

compte	nom	email	…
N1	Jean	…	
N2	Lucie	…	
N3	Marc	…	

Table Node

follower	followee
N1	N2
N1	N3
N2	N1
N2	N3
…	…

Table Edge

TROUVER LES VOISINS DIRECTS

compte	nom	email
N1	Jean	…
N2	Lucie	…
N3	Marc	…

- Nom des utilisateurs qui suivent 'Marc'?

  select B.nom
  from node A, node B, edge E
  where A.nom='Marc' **and** A.compte=E.followee
  and E.follower=B.compte

- Liste des nœuds atteignables depuis le compte de 'Marc' ?
  - Implique d'explorer le graphe depuis un nœud donné avec une profondeur d'exploration fixée

follower	followee
N1	N2
N1	N3
N2	N1
N2	N3
…	…

SQL 3 : REQUÊTES HIÉRARCHIQUES

SELECT select_list
FROM table_expression
[WHERE ...]
[START WITH start_expression]
CONNECT BY [NOCYCLE] { PRIOR parent_expr = child_expr |
child_expr = PRIOR parent_expr }
[ORDER SIBLINGS BY column1 [ASC | DESC] [, column2 [ASC | DESC]] ...
[GROUP BY ...]
[HAVING ...]

REQUÊTES HIÉRARCHIQUES

- START WITH indique le noeud de départ
- CONNECT BY PRIOR : règle de connexion entre les nœuds, spécifie la relation entre les tuples parent/enfant dans la hiérarchie.
- WHERE supprime les tuples de la hiérarchie qui ne satisfont pas la condition (on n'arrête pas la récursion)
- LEVEL : attribut permettant de retourner la profondeur du nœud par rapport à la racine
- NOCYCLE : ne retourne pas un message d'erreur si un cycle est rencontré
- SYS_CONNECT_BY_PATH : permet de construire le chemin depuis la racine
- CONNECT_BY_ROOT : utiliser le nœud racine dans une condition

(voir TME)

EXEMPLE DE REQUÊTES HIÉRARCHIQUES

Tous les subordonnés parisiens de Pierre?

select NAME, LEVEL
from EMP E
where E.TOWN='Paris'
start with E.NAME='Pierre'
connect by E.MGR = **prior** E.EMPNO;

Tous les supérieurs parisiens de Pierre?

select NAME,LEVEL
from EMP E
where E.TOWN='Paris'
start with E.NAME='Pierre'
connect by prior E.MGR = E.EMPNO;

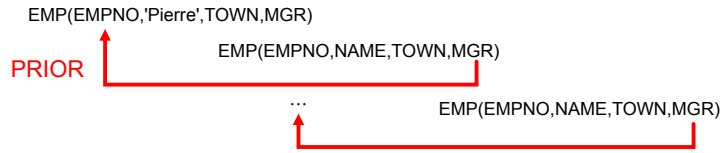

SQL3 : FACTORISATION AVEC WITH

WITH [RECURSIVE]
<vue V1> [(<liste_colonne1>)] **AS [(** <requête SQL Q1> **)],**
<vue V2> [(<liste_colonne2>)] **AS [(** <requête SQL Q2> **)], ...**
<requête SQL Q> ;

- Oracle: on ne met pas le mot clé RECURSIVE
- Requête Qi peut utiliser toutes les vues Vj pour j < i
- Récursion : Qi utilise la vue Vi (avec UNION ALL)
  - Qi: **select** … **from** (<requête>) **union all (**select … **from** Vi, …)

EXEMPLE RÉCURSION SQL3

EMP(ENO,NAME,TOWN,MGR)

Tous les subordonnés parisiens de Pierre?

```
WITH subordonne(SUBENO, SUBENAME, TOWN)
AS (SELECT DISTINCT sub.ENO, sub.NAME, sub.TOWN
    FROM EMP sup, EMP sub WHERE sup.NAME='Pierre'
                          AND sup.ENO = sub.MGR
    UNION ALL
    SELECT sub.ENO, sub.NAME, sub.TOWN
    FROM subordonne sup, EMP sub WHERE sup.ENO=sub.MGR)
SELECT * FROM subordonne where TOWN = 'Paris';
```

EXEMPLE RÉCURSION SQL3

EMP(ENO,NAME,TOWN,MGR)

Tous les supérieurs parisiens de Pierre?

```
WITH supérieur(SUPENO, SUPENAME, TOWN)
AS (SELECT DISTINCT sup.ENO, sup.NAME, sup.TOWN
    FROM EMP sup, EMP sub WHERE sub.NAME='Pierre'
                          AND sup.ENO = sub.MGR
    UNION ALL
    SELECT sup.ENO, sup.NAME, sup.TOWN
    FROM supérieur sub, EMP sup WHERE sup.ENO=sub.MGR)
SELECT * FROM supérieur where TOWN = 'Paris';
```

RÉCURSION EN PROFONDEUR OU EN LARGEUR

- Contrôler l'odre d'évaluation :

  SEARCH DEPTH | BREADTH FIRST BY <attr> **SET** <ordre>

```
WITH subordonne(SUBENO, SUBENAME, TOWN)
AS
(
    SELECT DISTINCT sub.ENO, sub.NAME, sub.TOWN
    FROM EMP sup, EMP sub WHERE sup.NAME='Pierre'
                          AND sup.ENO = sub.MGR
    UNION ALL
    SELECT sub.ENO, sub.NAME, sub.TOWN
    FROM subordonne sup, EMP sub WHERE sup.ENO=sub.MGR
)
SEARCH DEPTH FIRST BY SUBENO SET order1
SELECT * FROM subordonne where TOWN = 'Paris'
ORDER BY order1;
```

RÉCURSION ET CYCLE

- Détection de cycles :

  CYCLE <attr1> **SET** <attr2> **TO** <val1> **DEFAULT** <val2>

- attr2 = val1 quand un cycle est détecté sur l'attribute attr1 (attre = val2 sinon)
- la récursion s'arrête pour la ligne où le cycle est détécté

```
WITH subordonne(SUBENO, SUBENAME, TOWN)
AS (
     SELECT DISTINCT sub.ENO, sub.NAME, sub.TOWN
     FROM EMP sup, EMP sub WHERE sup.NAME='Pierre' AND sup.ENO = sub.MGR
  UNION ALL
     SELECT sub.ENO, sub.NAME, sub.TOWN
     FROM subordonne sup, EMP sub WHERE sup.ENO=sub.MGR
)
CYCLE SUBENO SET cyc TO 1 DEFAULT 0
SELECT * FROM subordonne where TOWN = 'Paris';
```

LIMITES DES BD RELATIONNELLES

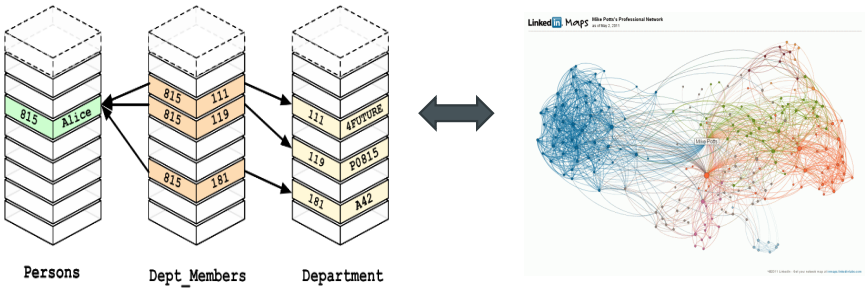

Source : neo4j.com

LIMITES DES BD RELATIONNELLES

- Modèle :
  - Le modèle relationnel est bien adapté pour des données structurées qui peuvent facilement être organisés en plusieurs tables
  - Un graphe est une structuration libre de nœuds divers connectés par des liens
  - Liens entre les noeuds modélisées par des tables supplémentaires → modifier le schéma pour ajouter de nouveaux types de données et de relations
- Requêtes
  - Les requêtes SQL récursives sont complexes, expliciter les liens avec joins
  - Les optimiseurs et structures d'index relationnels ne sont pas adaptés à l'évaluation de requêtes graphes => performances dégradées quand il existe beaucoup de relations

PERFORMANCE DES BD RELATIONNELLES

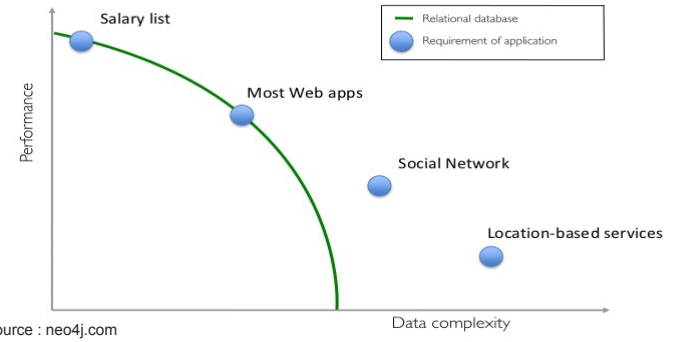

Source : neo4j.com

Alternative : BD ORIENTÉES GRAPHE

Source : neo4j.com

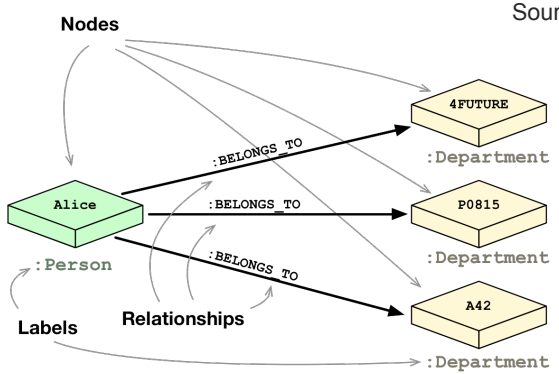

Remplacer les références logiques clés/clés étrangères par des pointeurs physiques → jointure = suivi de pointeurs

BD ORIENTÉES GRAPHES

- Organisées selon des modèle complexes et flexibles
- Stockage optimisé pour des structures fortement connexes (stockage dédié aux nœuds et aux arcs) et pour la lecture et le parcours du graphe
- Utilisation des algorithmes graphe optimisés avec des API intégrées
  - plus court chemin, centralité, etc
- Requêtes :
  - en temps linéaire (exponentiel pour SQL) lorsque le volume/connectivité/profondeur de parcours de données augmentent
  - traversent le graphe efficacement
  - adjacence entre les éléments voisins sans indexation : pointers physiques (enregistrés comme part entière de la donnée), évitent les jointures coûteuses

BD ORIENTÉES GRAPHES

Exemples de BD orientées graphe :

- AllegroGraph, ArrangoDB, GraphEngine, Sones, HypergraphDB
- Neo4j :
  - BD transactionnelle / ACID (Atomicité, Cohérence, Isolation, Durabilité)
  - haute disponibilité (mise ne place d'un cluster)
  - scalabilité : stocker et interroger des milliards de noeuds et de relations
  - utilisateurs : Viadeo, ebay, National Geographic, Cisco, Adobe, Meetic, SFR, Voyages-SNCF, etc

NEO4J : GRAPHE DE PROPRIÉTÉS

- Noeuds :
  - étiquettes pour différencier les nœuds
    - donnent un rôle/type à un nœud, plusieurs étiquettes possibles pour un nœuds
  - propriétés clef/valeur
- Relations :
  - nœud de départ, nœud d'arrivée
  - type de relation
  - propriétés clef/valeur

NEO4J : GRAPHE DE PROPRIÉTÉS

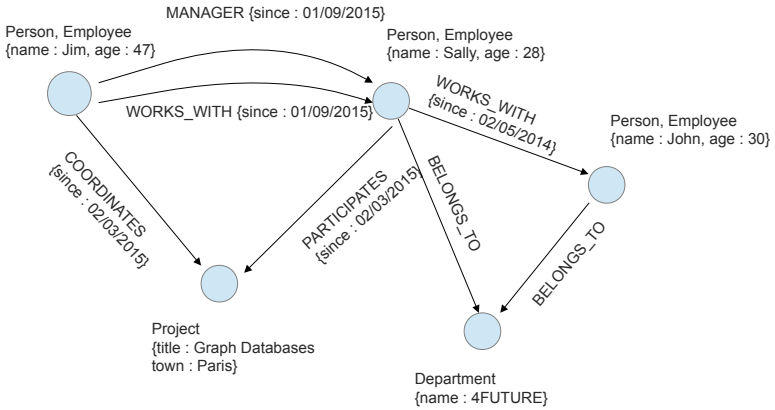

NEO4J : CYPHER

- Langage de requêtes déclaratif (inspiré de SQL)
- Motifs de chemins / graphes

Syntaxe :

- spécification de nœuds : (p : Person), (p : Person:Employee), (p:Person {name:Jim}), ()
- spécification de relations : (u) → (v), (u) -[r] → (v),
  (u) – [r : MANAGER|WORKS_WITH] → (v),
  (u) - [:COORDINATES {since:"02/03/2015"}] ->(p)
- motifs de chemins :
  - (u)-->(z)<--(v), (u)-->()<--(v), (u)--(v)
  - (u) - [*2] → (v) équivalent à (u) → () → (v)
  - (u) - [*3..5] → (v) : longueur entre 3 et 5 (relations)
  - (u) - [*3..] → (v) : chemin de longueur minimum 3
  - (u) - [*..5] → (v) : chemin de longueur maximum 5
  - (u) - [*] → (v) : n'importe quelle longueur

REQUÊTES CYPHER

- MATCH (m) : retourne les instances (bindings de variables) de motif m
- WHERE : prédicats pour filtrer les résultats
- RETURN : formatage des résultats sous la forme demandée:
  - valeurs scalaires, éléments de graph, chemins, collections ou même documents.
- CREATE : créé les nœuds ou les relations avec les étiquettes et les propriétés
- LIMIT : restriction de cardinalité
- ORDER BY : ordonnancement

EXEMPLES DE REQUÊTES

- Tous les nœuds du graphe
  MATCH(n) RETURN n
- Tous les nœuds qui on une relation avec un autre noeud
  MATCH(n) → () RETURN n
- Toutes les relations de John (indépendamment de la direction)
  MATCH (john {name :"John"}) – [r] - ()
  RETURN TYPE(r)
- Tous les noms d'employés avec les noms de leur département :
  MATCH (e: Employee) → (d: Department)
  RETURN e.name, d.name

EXEMPLES DE REQUÊTES

- Trouver Jim et ses subordonnés :

```
MATCH (jim :Person {name : 'Jim'}) - [:MANAGER]->(sub)
RETURN jim, sub
```

- Depuis quand participe Sally au projet "Graph Databases" ?

```
MATCH (sally:Employee { name : 'Sally' })
MATCH (projet:Project  { title :'Graph Databases' })
MATCH (sally)-[r:PARTICIPATES] → (projet)
RETURN r.since
```

- Tous les projets à Paris dans lesquels a travaillé Sally

```
MATCH (sally:Employee)-[:PARTICIPATES]->(project)
WHERE sally.name="Sally"   AND project.town ="Paris"
RETURN project.title;
```

EXEMPLES DE REQUÊTES

- Tous les projets dans lesquels a travaillé chaque employé avec les noms des chefs des projets

```
MATCH (e)-[:PARTICIPATES]->(p), (p)<-[:COORDINATES]-(c)
RETURN e.name, p.title, c.name;
```

- Qui est le plus âgé parmi Jim et Sally ?

```
MATCH(p : Person)
WHERE p.name='Jim' OR p.name='Sally'
RETURN p.name as oldest
ORDER BY p.age DESC  LIMIT 1
```

- Les 5 personnes les plus âgées :

```
MATCH (p:Person)
RETURN p.name
ORDER BY p.age DESC LIMIT 5;
```

EXEMPLES DE REQUÊTES

- Les 10 employés qui ont travaillé dans le plus de projets :

```
MATCH (e:Employee)-[:PARTICIPATES]->(p)
RETURN e.name, count(p)
ORDER BY count(p) DESC  LIMIT 10;
```

→ Autres fonctions d'agrégation : min, max, sum, collect

- Les projets dans lesquels travaille Sally et dans lesquels ne travaille pas John

```
MATCH (sally:Person {name:"Sally"})-[:PARTICIPATES]->(project),
MATCH (john:Person {name:"John"})
WHERE NOT (john)-[:PARTICIPATES]->(project)
RETURN DISTINCT project.title;
```

- Les employés avec lesquels travaillent ceux qui travaillent avec Jim et avec lesquels Jim n'a jamais travaillé:

```
MATCH (jim:Employe)-[:WORKS_WITH*2]->(fof)
 WHERE jim.name = "Jim" and NOT (jim)-[:WORKS_WITH]->(fof)
 RETURN DISTINCT fof.name;
```

EXEMPLES DE REQUÊTES

- La longueur du plus court chemin entre "Jim" et "John" :

```
MATCH p=shortestPath( (jim)-[*1..10]-(john) )
WHERE jim.name="Jim" and john.name = "John"
RETURN length(p)
```

- Tous les plus courts chemins entre "Jim" et "John" :

```
MATCH (jim : Person {name :'Jim'})
MATCH (john:Person {name :'John'}),
p = allShortestPaths((jim)-[*1..10]-(john))
RETURN p
```

EXEMPLES DE REQUÊTES

- Afficher le nom des personnes sur le plus court chemin :

```
MATCH (sally:Person {name:"Sally"}), (jim:Person {name:"Jim"})
MATCH p=shortestPath((sally)-[*1..10]->(jim))
RETURN EXTRACT ( n in nodes(p) | n.name );
```

- Le collègue de Jim et le collègue de celui-ci

```
MATCH (jim)-[:WORKS_WITH*1..2]-(foaf)
WHERE jim.name="Jim"
RETURN foaf.name
```

Clause WITH

- Utilisée pour relier différentes parties de la requête. Exemples :
  - Pour pouvoir appliquer un filtre sur le résultat d'une fonction d'agrégation

```
MATCH (sally {name : 'Sally'})-->(other)-->()
WITH other, count(*) AS nbfoaf
 WHERE nbfoaf > 2
 RETURN other.name, nbfoaf
```

- Trier les résultats avant de les retourner dans une liste

```
MATCH (n) WITH n
ORDER BY n.name DESC LIMIT 4
RETURN collect(n.name)
```

Clause WITH

- Faire des traitements successifs

```
MATCH (p {title: 'Graph Databases'})--(other)
WITH other, p
ORDER BY other.name DESC LIMIT 1
MATCH (other)--(neigh) WHERE neigh <> p
 RETURN distinct neigh.name
```

- (En partant de 'Graph Databases', trouver les voisins, les classer par nom, en garder seulement les 2 premiers et afficher ensuite leur voisins)